

UNIVERSITÀ DEGLI STUDI DI SALERNO

DIPARTIMENTO DI INFORMATICA

Corso di Machine Learning

Predict Students' Dropout and Academic Success

Sviluppo di un Modello di Classificazione per la Previsione del
Successo Accademico

Studente:

Dario Balestrieri 0512118165

ANNO ACCADEMICO 2025/2026

Indice

1	Obiettivo del Progetto	2
2	Analisi Esplorativa dei Dati (EDA)	2
2.1	Distribuzione del Target Iniziale	3
2.2	Analisi delle Variabili Demografiche	4
3	Data Cleaning e Preprocessing	5
3.1	Controllo Integrità: Valori Nulli e Duplicati	5
3.2	Gestione della Classe "Enrolled"	5
4	Feature Engineering	6
4.1	Raggruppamento in Macro-Categorie	6
4.2	One-Hot Encoding	6
5	Sviluppo e Selezione del Modello	7
5.1	Campionamento Stratificato e Riproducibilità	7
5.2	Scelta degli Algoritmi: Baseline vs Ensemble	7
6	Risultati e Valutazione delle Performance	7
6.1	Confronto Prestazionale tra i Modelli	7
6.2	Performance della Regressione Logistica	8
6.3	Analisi dell'Importanza delle Feature (Driver di Successo)	9
6.4	Analisi della Confidenza del Modello	10
7	Conclusioni	10

1 Obiettivo del Progetto

L'abbandono scolastico a livello universitario rappresenta una sfida significativa sia per gli studenti che per le istituzioni accademiche. Identificare precocemente i soggetti a rischio è fondamentale per attuare politiche di tutoraggio e supporto mirate.

Pertanto, l'obiettivo di questo progetto è implementare una pipeline completa di Machine Learning capace di analizzare dati demografici, socio-economici e accademici per prevedere, tramite classificazione binaria, se uno studente completerà gli studi (*Graduate*) o si ritirerà (*Dropout*). Tale strumento predittivo permetterà di intercettare in anticipo le situazioni di criticità, fornendo alle istituzioni i mezzi per aiutare tempestivamente gli studenti a concludere con successo il proprio percorso.

2 Analisi Esplorativa dei Dati (EDA)

Il dataset analizzato comprende record relativi a oltre 3.000 studenti. Le informazioni fornite coprono diversi aspetti della vita dello studente e sono categorizzabili in tre macro-aree principali:

- **Dati Demografici e Background:** Età al momento dell'iscrizione, nazionalità, stato civile, il livello di istruzione e l'occupazione dei genitori.
- **Dati Socio-Economici:** Stato dei pagamenti delle tasse universitarie, presenza di borse di studio, e indicatori macroeconomici come il tasso di inflazione o il PIL al momento dell'immatricolazione.
- **Dati Accademici:** Unità curriculari seguite, valutazioni ottenute e crediti approvati nel corso del primo e del secondo semestre.

2.1 Distribuzione del Target Iniziale

Il primo passo dell'analisi è consistito nella verifica del bilanciamento della variabile target. Originalmente, il dataset presentava tre possibili esiti per la carriera accademica: studenti laureati (*Graduate*), studenti ritirati (*Dropout*) e studenti ancora in corso di studi (*Enrolled*).




Figura 1: Distribuzione iniziale delle classi nel dataset, comprensiva degli studenti ancora in corso (Enrolled).

L'analisi visiva ha confermato che la classe *Graduate* rappresenta la maggioranza relativa, seguita da una percentuale consistente di *Dropout* (circa il 32%), evidenziando la gravità del fenomeno dell'abbandono.

2.2 Analisi delle Variabili Demografiche

Successivamente, sono state esplorate le distribuzioni delle principali feature. In particolare, l'età degli studenti al momento dell'immatricolazione è stata analizzata per individuare eventuali anomalie o trend particolari.




Figura 2: Boxplot dell'età degli studenti al momento dell'iscrizione, utile per individuare la presenza di studenti fuori quota standard (outlier).

Il boxplot evidenzia come la stragrande maggioranza degli studenti si iscriva in un'età canonica (tra i 18 e i 20 anni), ma mostra anche una "coda" di studenti più maturi, che potrebbero presentare dinamiche di abbandono differenti.

3 Data Cleaning e Preprocessing

Prima di poter applicare qualsiasi algoritmo di Machine Learning, il dataset è stato sottoposto a una rigorosa fase di pulizia e trasformazione.

3.1 Controllo Integrità: Valori Nulli e Duplicati

Un modello predittivo è tanto affidabile quanto lo sono i dati su cui viene addestrato. È stata quindi effettuata una verifica programmatica per assicurarsi dell'assenza di valori mancanti (NaN) o di righe duplicate all'interno del dataset.

#	Column	Non-Null Count	Dtype
0	Marital status	4424 non-null	int64
1	Application mode	4424 non-null	int64
2	Application order	4424 non-null	int64
3	Course	4424 non-null	int64
4	Daytime/evening attendance	4424 non-null	int64
5	Previous qualification	4424 non-null	int64
6	Nacionality	4424 non-null	int64
7	Mother's qualification	4424 non-null	int64
8	Father's qualification	4424 non-null	int64
9	Mother's occupation	4424 non-null	int64
10	Father's occupation	4424 non-null	int64
11	Displaced	4424 non-null	int64
12	Educational special needs	4424 non-null	int64
13	Debtor	4424 non-null	int64
14	Tuition fees up to date	4424 non-null	int64
15	Gender	4424 non-null	int64
16	Scholarship holder	4424 non-null	int64
17	Age at enrollment	4424 non-null	int64
18	International	4424 non-null	int64
19	Curricular units 1st sem (credited)	4424 non-null	int64
20	Curricular units 1st sem (enrolled)	4424 non-null	int64
21	Curricular units 1st sem (evaluations)	4424 non-null	int64
22	Curricular units 1st sem (approved)	4424 non-null	int64
23	Curricular units 1st sem (grade)	4424 non-null	float64
24	Curricular units 1st sem (without evaluations)	4424 non-null	int64
25	Curricular units 2nd sem (credited)	4424 non-null	int64
26	Curricular units 2nd sem (enrolled)	4424 non-null	int64
27	Curricular units 2nd sem (evaluations)	4424 non-null	int64
28	Curricular units 2nd sem (approved)	4424 non-null	int64
29	Curricular units 2nd sem (grade)	4424 non-null	float64
30	Curricular units 2nd sem (without evaluations)	4424 non-null	int64
31	Unemployment rate	4424 non-null	float64
32	Inflation rate	4424 non-null	float64
33	GDP	4424 non-null	float64
34	Target	4424 non-null	str

Figura 3: Verifica programmatica dell'assenza di valori nulli all'interno del dataset.

L'assenza di valori nulli ha permesso di evitare complesse tecniche di imputazione, garantendo la totale fedeltà dei dati originali.

3.2 Gestione della Classe "Enrolled"

Come discusso nella fase di EDA, il target includeva la classe *Enrolled*. Mantenere questa classe avrebbe introdotto un elevato grado di rumore statistico: uno studente attualmente in corso potrebbe infatti, in futuro, sia laurearsi che ritirarsi. Per isolare i veri driver del successo e del fallimento accademico, i record appartenenti alla classe *Enrolled* sono stati deliberatamente rimossi. Questa scelta metodologica ha permesso di convertire il task in un problema di **classificazione binaria netta** (0 = Dropout, 1 = Graduate).

4 Feature Engineering

La fase di Feature Engineering si è rivelata cruciale per ottimizzare lo spazio delle feature e migliorare la generalizzazione degli algoritmi.

4.1 Raggruppamento in Macro-Categorie

Alcune variabili categoriche del dataset originale presentavano un'altissima cardinalità. In particolar modo, le professioni e i titoli di studio dei genitori erano frammentati in centinaia di codici specifici e molto dettagliati.

L'utilizzo diretto di queste variabili avrebbe generato una matrice estremamente sparsa dopo l'operazione di encoding, aumentando il rischio di *overfitting* (maledizione della dimensionalità). Per risolvere il problema, le diverse occupazioni sono state mappate logico-semanticamente e aggregate in Macro-Categorie più ampie e robuste, quali:

- **Lavoro Qualificato** (es. medici, ingegneri, dirigenti)
- **Lavoro Non Qualificato** (es. operai, personale di servizio)
- **Istruzione Superiore** (es. lauree triennali e magistrali)
- **Istruzione di Base** (es. scuola primaria e secondaria)

4.2 One-Hot Encoding

Poiché i modelli matematici di classificazione operano esclusivamente su vettori numerici, tutte le variabili categoriche testuali (comprese le macro-categorie appena create) sono state convertite. Si è optato per la tecnica del *One-Hot Encoding*, generando variabili *dummy* binarie (0 o 1) per ogni categoria. Questo approccio è matematicamente essenziale per evitare che l'algoritmo interpreti erroneamente i numeri assegnati alle categorie come una scala gerarchica o di valore.

5 Sviluppo e Selezione del Modello

Concluso il preprocessing, l'attenzione si è spostata sulla costruzione del motore predittivo, seguendo le *best practice* di partizionamento e validazione.

5.1 Campionamento Stratificato e Riproducibilità

La matrice delle feature ($\mathbf{X}$) è stata separata dal vettore target ($\mathbf{y}$). Il dataset è stato poi suddiviso in un set di addestramento (80%) e un set di test (20%).

Durante questa operazione, sono stati applicati due parametri fondamentali:

- **stratify=y**: Ha garantito che il campionamento casuale mantenesse la medesima proporzione di studenti *Dropout* e *Graduate* presente nel dataset originale sia nel set di addestramento che in quello di test. Questo impedisce di addestrare il modello su campioni sbilanciati che favorirebbero la classe maggioritaria.
- **random_state=42**: Fissare il seed del generatore pseudo-casuale ha assicurato la totale riproducibilità dell'esperimento. Chiunque esegua il codice otterrà le medesime partizioni e, di conseguenza, i medesimi risultati prestazionali.

5.2 Scelta degli Algoritmi: Baseline vs Ensemble

Per valutare la complessità intrinseca del problema, sono stati messi in competizione due algoritmi fondati su logiche matematiche diametralmente opposte:

1. **Regressione Logistica**: Scelta come *baseline* per la sua natura lineare e trasparente. Se un modello lineare ottiene buoni risultati, significa che le relazioni causa-effetto nei dati sono dirette.
2. **Random Forest Classifier**: Scelto come "sfidante" non lineare. Essendo un modello *ensemble* basato su centinaia di alberi decisionali, è ideale per catturare pattern complessi e interazioni nascoste tra le variabili. Inoltre, possiede la capacità nativa di calcolare l'importanza delle singole feature.

6 Risultati e Valutazione delle Performance

Il verdetto empirico sui dati di test ha fornito risultati estremamente incoraggianti.

6.1 Confronto Prestazionale tra i Modelli

Per determinare l'algoritmo ottimale per il task di classificazione, i risultati della Regressione Logistica sono stati confrontati direttamente con quelli ottenuti dal Random Forest. Il confronto è stato effettuato valutando le metriche principali calcolate sulle previsioni del set di test.

Modello	Accuracy	Precision (Dropout)	Recall (Dropout)
Regressione Logistica	92%	94%	84%
Random Forest Classifier	91%	92%	81%

Tabella 1: Confronto delle metriche di performance sui dati di test indipendenti.

Come si evince dalla Tabella, la Regressione Logistica non solo eccelle nell'accuratezza globale, ma garantisce prestazioni superiori nell'individuazione dei casi critici. Presenta infatti una maggiore capacità di intercettare gli abbandoni (*Recall*) mantenendo al minimo i falsi allarmi (*Precision*), confermandosi il modello superiore per questo specifico problema.

6.2 Performance della Regressione Logistica

Contrariamente all'assunto che modelli più complessi performino necessariamente meglio, la **Regressione Logistica** ha ottenuto un'eccellente **accuratezza del 92%**, superando di poco il Random Forest. Questo risultato dimostra che, una volta puliti adeguatamente i dati, il problema dell'abbandono accademico segue dinamiche prevalentemente lineari.




Figura 4: Matrice di Confusione della Regressione Logistica valutata sui dati di test.

L'analisi della Matrice di Confusione conferma la validità del modello in un'ottica di prevenzione reale. Focalizzandosi sulla classe *Dropout* (la classe critica per l'istituzione), il modello raggiunge:

- **Precision (94%):** L'affidabilità è altissima. Quando il modello etichetta uno studente come a rischio abbandono, la previsione è corretta nel 94% dei casi, riducendo al minimo i falsi allarmi.
- **Recall (84%):** Il modello possiede un'ottima sensibilità, riuscendo a intercettare l'84% del totale effettivo degli abbandoni presenti nel test set.

6.3 Analisi dell'Importanza delle Feature (Driver di Successo)

Sebbene non sia stato scelto come modello finale per le previsioni, il Random Forest è stato utilizzato come strumento esplorativo per generare il ranking della *Feature Importance*, permettendo di spiegare il "perché" delle previsioni.




Figura 5: Ranking delle variabili più influenti calcolato tramite Random Forest.

Il grafico rivela in modo inequivocabile i driver del successo o del fallimento accademico:

1. **Prestazioni del Secondo Semestre:** Il numero di esami superati (*Curricular units 2nd sem - approved*) e le valutazioni ottenute in questa fase costituiscono il predittore più forte in assoluto.
2. **Prestazioni del Primo Semestre:** Il successo nella primissima fase del percorso universitario crea lo slancio necessario per evitare l'abbandono.
3. **Regolarità Economica:** Lo stato dei pagamenti (*Tuition fees up to date*) si posiziona tra i vertici della classifica, confermando che l'aspetto finanziario incide più del background socio-culturale della famiglia di origine.

6.4 Analisi della Confidenza del Modello

Per confermare l'assenza di overfitting e misurare il grado di "certezza" matematica dell'algoritmo, è stata analizzata la distribuzione delle probabilità previste in output dalla Regressione Logistica.




Figura 6: Distribuzione bimodale delle probabilità previste dalla Regressione Logistica.

Il grafico mostra una polarizzazione ideale: la distribuzione è spiccatamente bimodale, con picchi pronunciati vicino allo 0 (assoluta sicurezza di Dropout) e all'1 (assoluta sicurezza di Graduate). La totale assenza di "montagne" nella zona centrale (intorno allo 0.5) certifica che il modello raramente è incerto: la maggior parte degli studenti viene classificata con una confidenza molto elevata.

7 Conclusioni

L'approccio metodologico adottato ha dimostrato che l'abbandono accademico non è un evento imprevedibile, ma un fenomeno fortemente tracciabile già al termine del primo anno di corso.

L'utilizzo di un rigoroso processo di *Data Cleaning* e *Feature Engineering*, unito all'applicazione di un modello lineare robusto, ha permesso di ottenere previsioni altamente affidabili, con un'accuratezza del 92% e tassi di falso positivo trascurabili.

Le evidenze emerse dalla *Feature Importance* sottolineano l'urgenza di focalizzare gli sforzi di tutoraggio sul monitoraggio continuo delle performance curriculari già dai primissimi semestri, abbinato a un controllo sulle criticità di natura economica.