

UNIVERSITÀ DEGLI STUDI DI SALERNO

DIPARTIMENTO DI INFORMATICA

Corso di Machine Learning

Predict Students' Dropout

Sviluppo di un Modello di Classificazione per la Previsione del
Successo Accademico

Studente:

Dario Balestrieri 0512118165

ANNO ACCADEMICO 2025/2026

Indice

1	Obiettivo del Progetto	2
2	Analisi Esplorativa dei Dati (EDA)	2
3	Preprocessing e Feature Engineering	3
4	Sviluppo del Modello e Risultati	3
5	Analisi dell'Importanza delle Feature	4
6	Analisi della Confidenza del Modello	4
7	Conclusioni	5

1 Obiettivo del Progetto

L'abbandono scolastico a livello universitario rappresenta una sfida significativa sia per gli studenti che per le istituzioni accademiche. Identificare precocemente i soggetti a rischio è fondamentale per attuare politiche di tutoraggio e supporto mirate.

L'obiettivo di questo progetto è implementare una pipeline completa di Machine Learning capace di analizzare dati demografici, socio-economici e accademici per prevedere, tramite classificazione binaria, se uno studente completerà gli studi (*Graduate*) o si ritirerà (*Dropout*).

2 Analisi Esplorativa dei Dati (EDA)

Il dataset analizzato comprende record relativi a oltre 3.000 studenti, descritti da molteplici variabili riconducibili al background familiare, alla regolarità economica e al rendimento didattico.

La prima fase ha previsto l'esplorazione visiva della variabile target per comprendere il bilanciamento delle classi.




Figura 1: Distribuzione delle classi nel dataset: confronto tra Dropout e Graduate.

Dall'analisi visiva è stato possibile notare la distribuzione iniziale e pianificare la successiva fase di pulizia, in cui gli studenti ancora in corso (*Enrolled*) sono stati rimossi per semplificare il task in un problema di classificazione binaria netta.

3 Preprocessing e Feature Engineering

Per ottimizzare la dimensionalità del dataset e migliorare la capacità di generalizzazione dei modelli, è stato effettuato un processo di Feature Engineering sulle variabili categoriche ad alta cardinalità (come le professioni dei genitori).

Sono state create macro-categorie per raggruppare professioni e titoli di studio simili. Successivamente, queste variabili categoriche sono state convertite in formato numerico tramite tecnica *One-Hot Encoding* (creazione di variabili *dummy*), un passaggio matematico essenziale per consentire agli algoritmi di elaborare correttamente le informazioni.

4 Sviluppo del Modello e Risultati

Sono state testate diverse architetture di classificazione. Il dataset è stato diviso in set di addestramento (80%) e di test (20%) tramite un partizionamento stratificato, garantendo che la proporzione originale di Dropout e Graduate venisse mantenuta in entrambi gli insiemi.

La **Regressione Logistica** si è dimostrata il modello più performante, raggiungendo un'eccellente **accuratezza del 92%** sui dati di test, superando leggermente i modelli non lineari come il Random Forest.




Figura 2: Matrice di Confusione della Regressione Logistica. Si evince un basso tasso di falsi negativi e falsi positivi.

Come si evince dalla Matrice di Confusione (Figura 2), il modello presenta metriche notevoli per la prevenzione dell'abbandono: una *Precision* del 94% (le previsioni di abbandono sono quasi sempre esatte) e una *Recall* dell'84% (riesce a individuare la grande maggioranza degli studenti effettivamente a rischio).

5 Analisi dell'Importanza delle Feature

Per rendere il modello interpretabile e comprendere i fattori determinanti per il successo accademico, è stato addestrato un modello *Random Forest* per estrarre la *Feature Importance*.




Figura 3: Ranking delle variabili più influenti: il rendimento accademico risulta il fattore dominante.

Il grafico (Figura 3) evidenzia in modo inequivocabile i principali driver predittivi:

- **Prestazioni del Secondo Semestre:** Il superamento degli esami (*Curricular units 2nd sem (approved)*) è il predittore più forte in assoluto.
- **Prestazioni del Primo Semestre:** Crea l'inerzia necessaria per il proseguimento degli studi.
- **Fattori Economici:** La regolarità nei pagamenti (*Tuition fees up to date*) si conferma tra i primissimi fattori d'influenza, superando l'impatto dell'età o del background genitoriale.

6 Analisi della Confidenza del Modello

In un contesto reale di prevenzione, è cruciale non solo che il modello indovini la classe, ma che sia "sicuro" della propria previsione. È stata quindi analizzata la distribuzione delle probabilità previste dalla Regressione Logistica.




Figura 4: Distribuzione delle probabilità previste per la classe Graduate. Si nota un’elevata polarizzazione.

Come illustrato in Figura 4, la distribuzione è spiccatamente bimodale. I picchi pronunciati vicino allo 0 (certezza di Dropout) e vicino all’1 (certezza di Graduate), uniti alla scarsità di osservazioni nella zona centrale (0.5), confermano la stabilità decisionale del modello e l’alto potere discriminante delle feature selezionate.

7 Conclusioni

L’elevata accuratezza ottenuta su dati di test indipendenti, supportata da una rigorosa pulizia dei dati e dalla validazione delle probabilità, conferma la solidità dei risultati. Il progetto dimostra che il successo accademico è fortemente determinabile già dalla performance del primo anno. Questo modello si pone come un efficace strumento integrabile nei sistemi di *Early Warning* universitari, capace di trasformare i dati storici in azioni di supporto preventive.